El Everest es pan comido:
Escala fácilmente con Cassandra

everis
an NTT DATA Company

Universidad de Alcalá

UAH

Javier Gómez Santos
Data Alchemist

everis
an NTT DATA Company

Para hablar del evento

@everis

@Javi_Pronoide

#Cassandra

#BigData

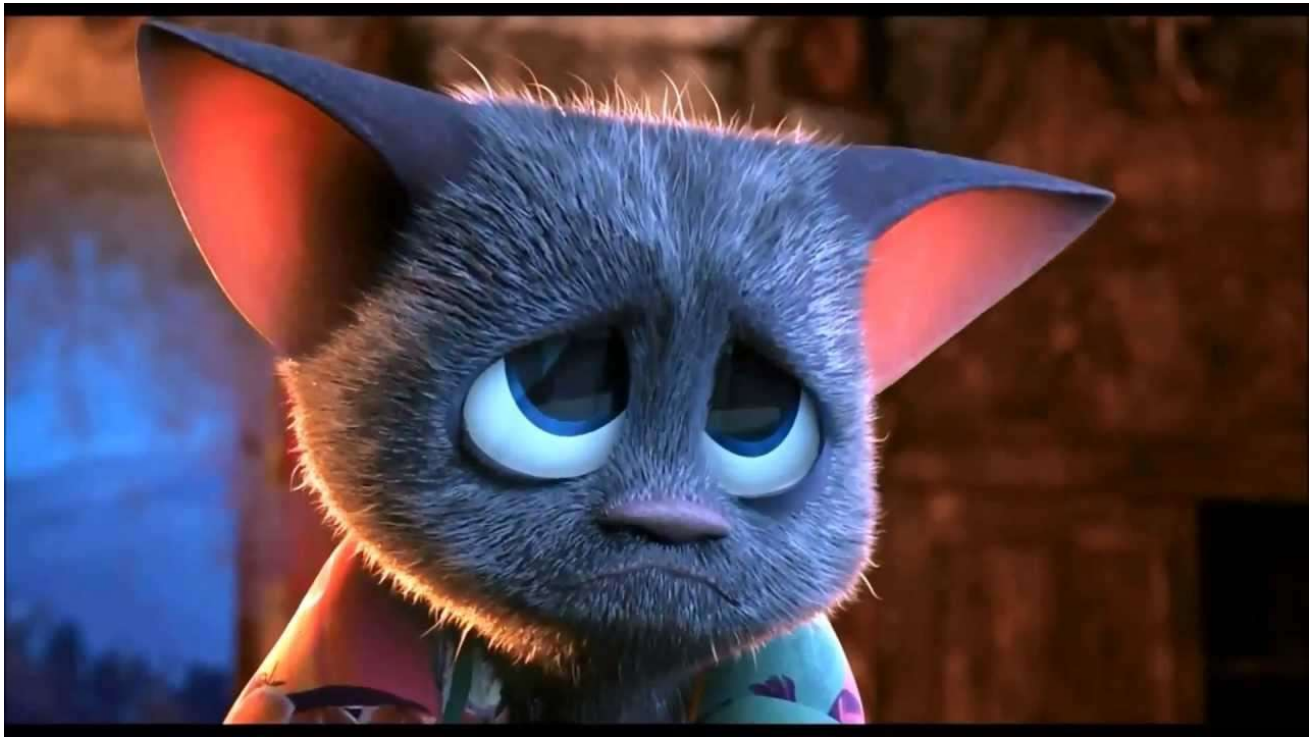

everis
an NTT DATA Company

Big Data, los orígenes

Crecimiento de datos en los últimos años

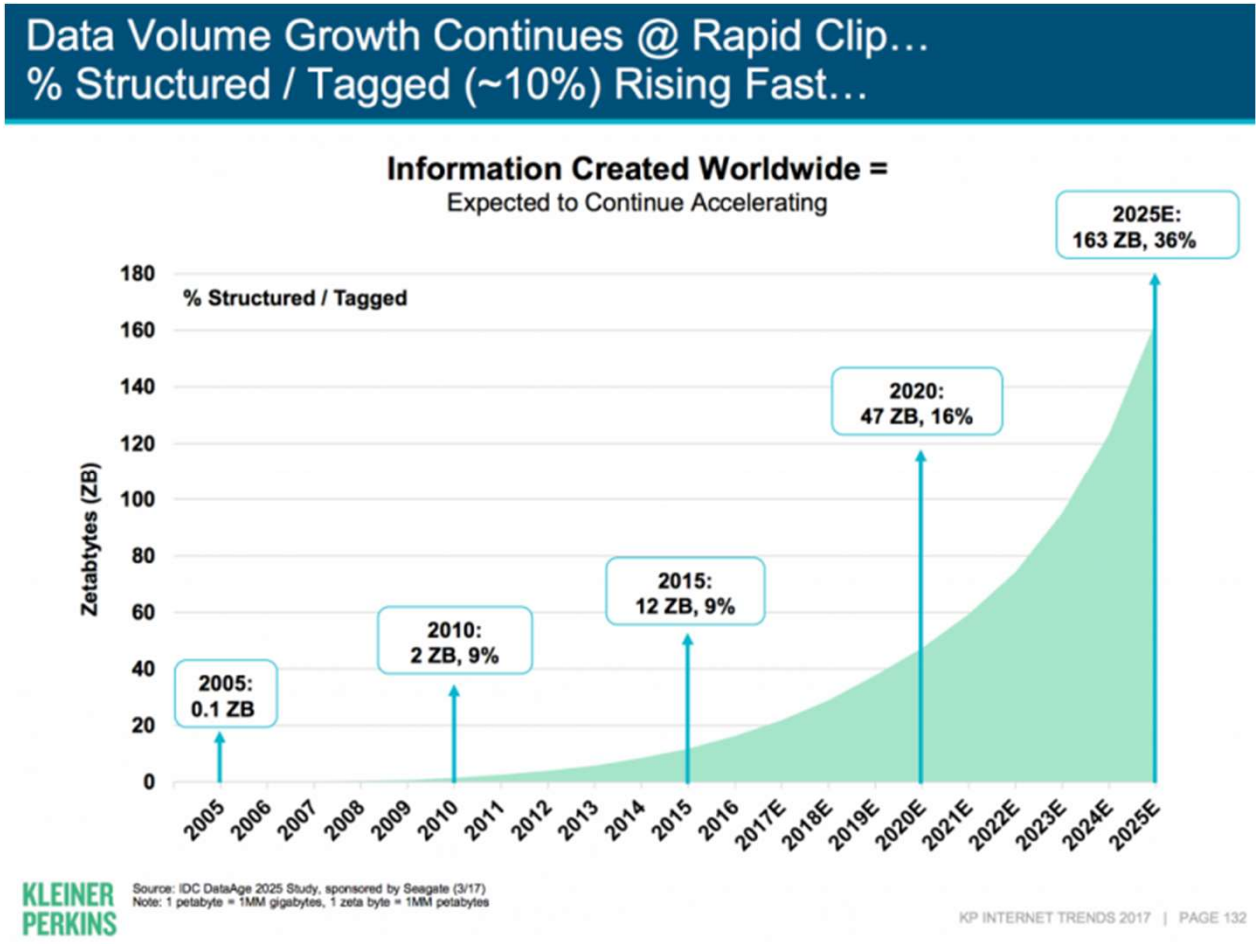

everis
an NTT DATA Company

Imposible para gestionar por un sistema tradicional

everis
an NTT DATA Company

¿Qué enfoques aportan las BBDD NoSQL?

- Distribuye la información a través de múltiples nodos
- Es más laxo con la consistencia
- Es más laxo con los esquemas
- Busca optimizar la información para adaptarla a las necesidades actuales

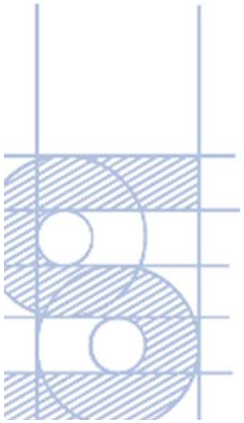

everis
an NTT DATA Company

Hay 4 grandes enfoques a las bases de datos no-relacionales:

- Grafos
- Clave-Valor
- Documento
- Column Family

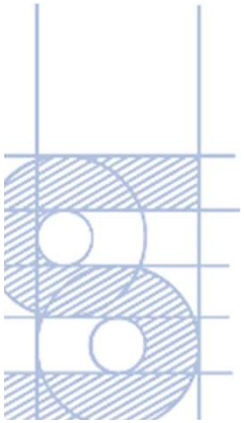

Grafos

Los elementos están distribuidos como vértices de un grafo, siendo las uniones entre vértices las relaciones de ambos (con propiedades).

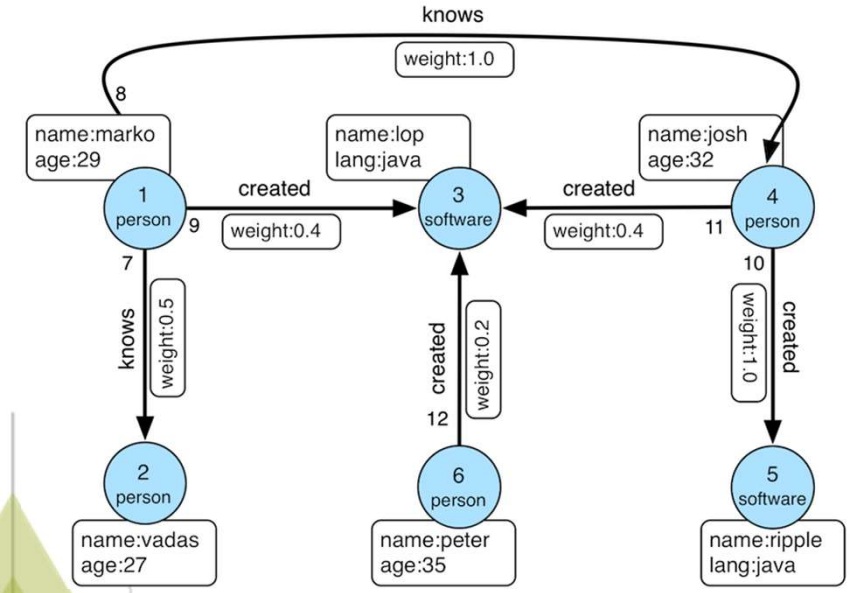

Gremlin

$G = (V, E)$

everis
an NTT DATA Company

Clave-Valor

Existen claves que enlazan a un conjunto de valores asociados a la misma de cualquier tipo

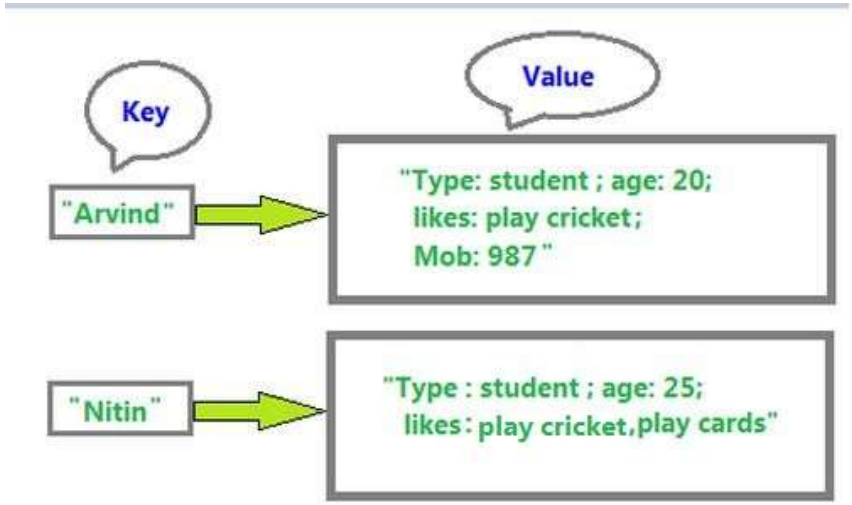

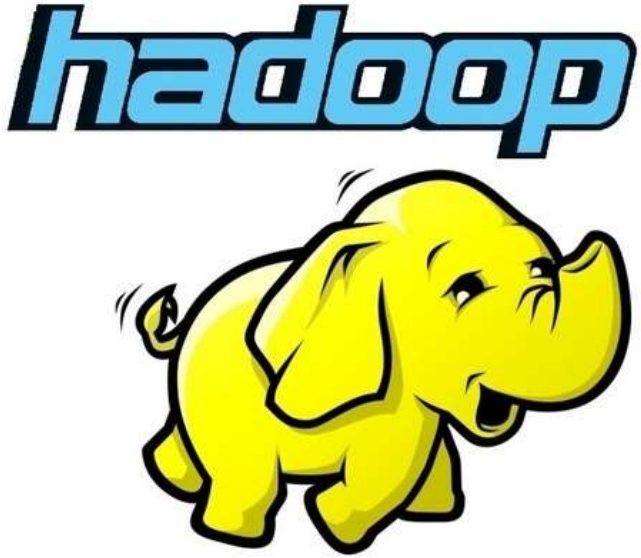

everis
an NTT DATA Company

Documento

Se almacenan conjuntos de documentos (JSON) que pueden ser consultados en su totalidad o en parte.

Students Document

```
{
        _id : "5373aadadcac133aad5b6660",
        name : "kaushal patel",
        email : "kp@example.com",
        courses : {
                course_name : "java",
                fees : "5000",
                duration : "3",
                professor : "g.r."
        }
}
```

Powered By : pingax.com

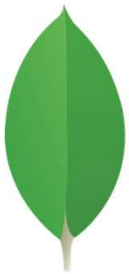

mongoDB®

everis
an NTT DATA Company

Column Family

Las claves enlazan con un conjunto de columnas

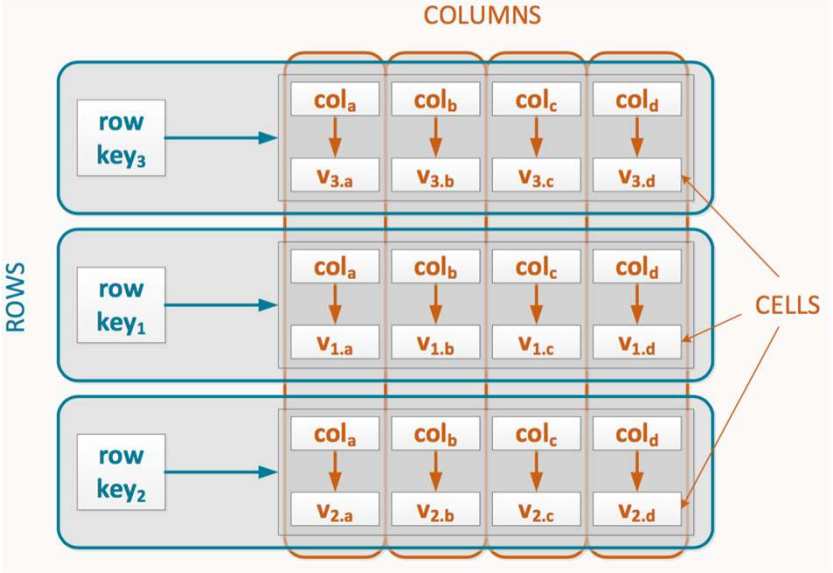

everis
an NTT DATA Company

El teorema CAP

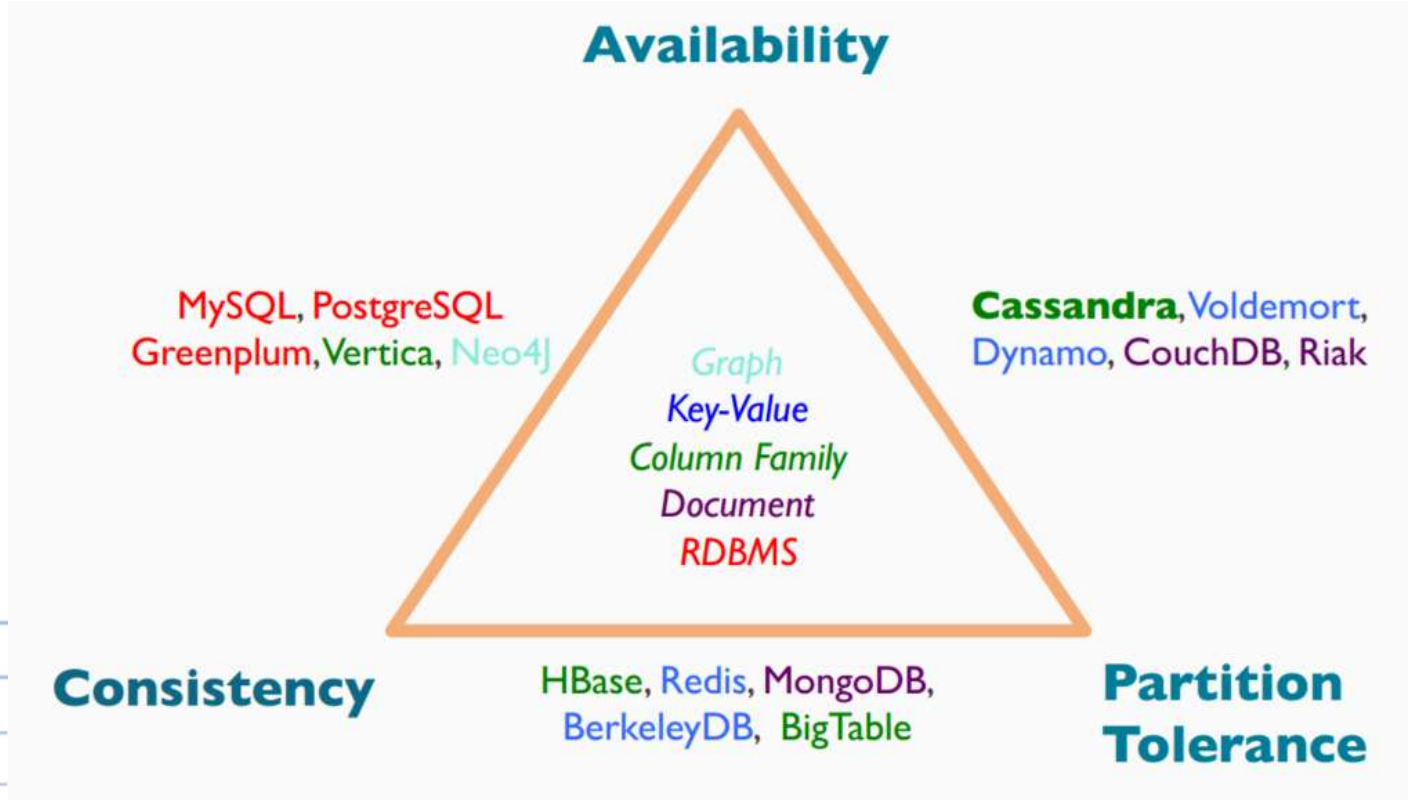

everis

an NTT DATA Company

everis
an NTT DATA Company

ADVERTENCIA:

Esto es un taller práctico

Si en algún momento te quedaras atascado, ejecuta los scripts que hay en tu **home**, en la carpeta **SoyMuyVago**

everis
an NTT DATA Company

¿Qué es Cassandra?

Características

- Una base de datos **NoSQL** basada en **Column Families**.
- Posee un **esquema definido**, pero **flexible**, que permite su alteración.
- Usa un modelo **totalmente distribuido**, sin nodos maestros.

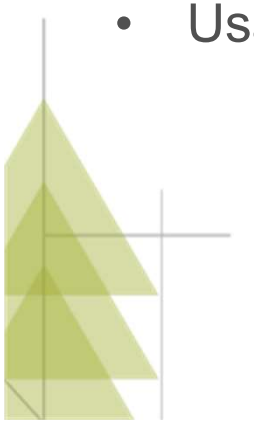

everis
an NTT DATA Company

A trabajar se ha dicho

Vamos a instalar Cassandra y levantar el primer nodo

- Verificamos fichero /etc/hosts y nuestro hostname
- Verificamos JDK
- Descomprimimos Cassandra (y lo llevamos a $home/cassandra_1)
- Configuramos ficheros “cassandra.yaml” y “cassandra-env.sh”
  - MAX_HEAP, INITIAL_HEAP y JMX_PORT
  - cluster_name, seeds, listen_address, rpc_address
    - Listen_address → nodos
    - Rpc_address → clientes
    - Broadcast_address → si los nodos se comunican con otra ip externa
- Levantamos Cassandra

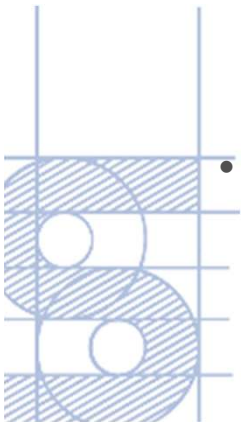

everis
an NTT DATA Company

¿Qué es Cassandra?

Posee CQL, un lenguaje de consultas similar al SQL

```
-- Inserts or updates
INSERT INTO Standard1 (KEY, col0, col1)
VALUES (key, value0, value1)
```

vs.

```
-- Inserts or updates
UPDATE Standard1
SET col0=value0, col1=value1 WHERE KEY=key
```

everis
an NTT DATA Company

Keyspace

División lógica en la que vamos a trabajar

Crear un Keyspace:

```
CREATE KEYSPACE nombre_keyspace
WITH replication={'class':'SimpleStrategy', 'replication_factor':3};
```

Asociar un Keyspace a la sesión actual de **cqlsh**

```
USE nombre_keyspace
```

Borrar un Keyspace y todos los datos que este posea

```
DROP KEYSPACE nombre_keyspace
```

everis
an NTT DATA Company

Table

Abstracción de una Column Family

```
CREATE TABLE performer (
        name VARCHAR PRIMARY KEY,
        type VARCHAR,
        country VARCHAR,
        style VARCHAR,
        founded INT,
        born INT,
        died INT );
```

```
CREATE TABLE tracks_by_album (
        album_title VARCHAR,
        year INT,
        performer VARCHAR STATIC,
        genre VARCHAR STATIC,
        number INT,
        track_title VARCHAR,
        PRIMARY KEY
        ((album_title,year),number));
```

everis
an NTT DATA Company

CRUD

Acceso a los datos a través de la Partition Key

Insertar:
Insert into performer (name, type) values (‘Paco’, ‘Cantautor’);

Actualizar:
Update performer set type = ‘Cantante’ where name=‘Paco’;

Borrar:
Delete performer where name=‘Paco’;

Leer:
Select * from perfomer where name=‘Paco’:

everis
an NTT DATA Company

A trabajar se ha dicho

Vamos a lanzar nuestras primeras querys

- Asegurémonos de que Cassandra está levantado (Si es necesario, usar “nodetool”)
- Vamos a crear un keyspace
- Vamos a crear una tabla
- Insertaremos 1 dato
- Haremos un import de un CSV

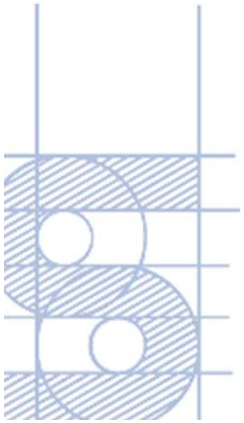

¿Qué es Cassandra?

Clúster Cassandra

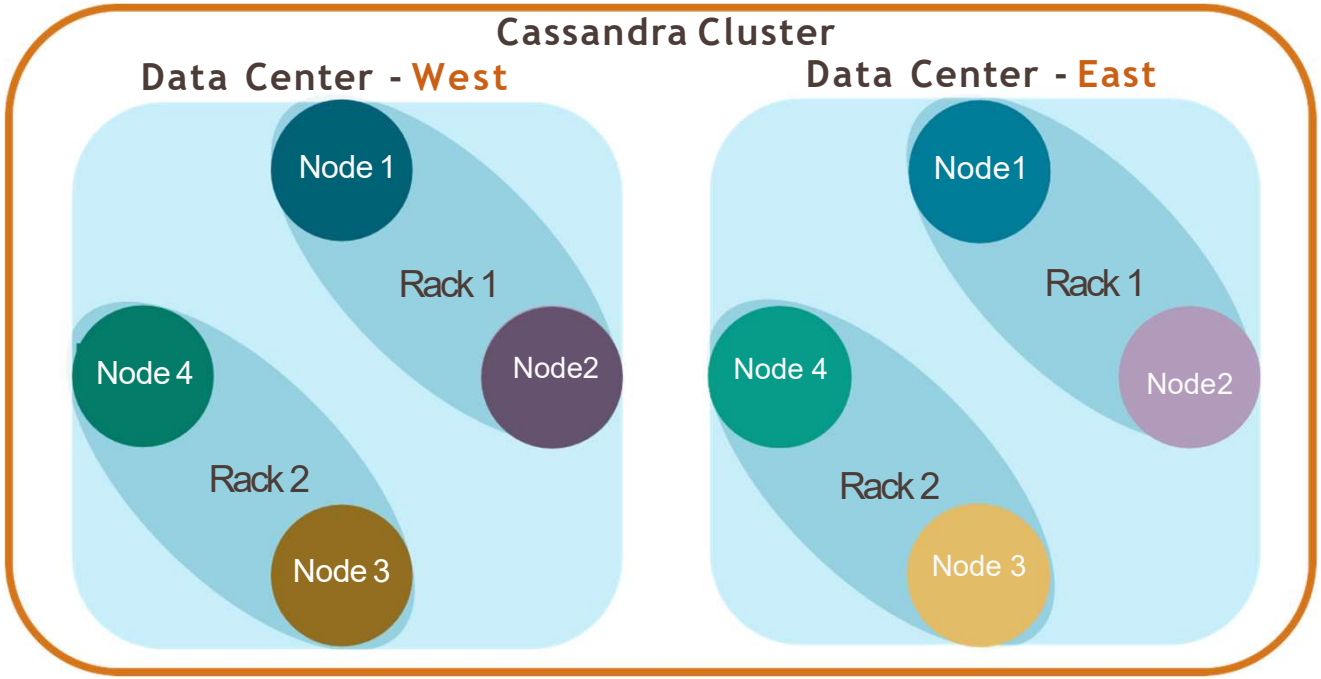

everis
an NTT DATA Company

¿Qué es Cassandra?

Escalado horizontal

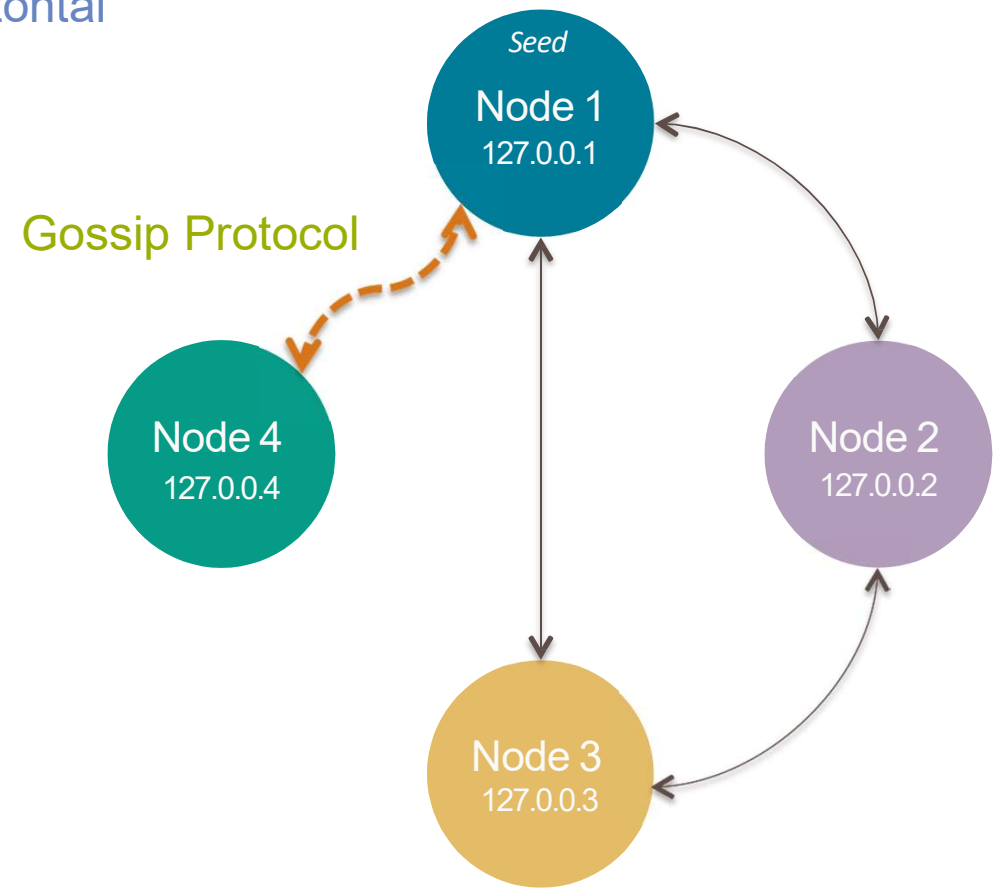

everis
an NTT DATA Company

A trabajar se ha dicho

Vamos a instalar un segundo nodo de Cassandra

- Repetimos los pasos de la primera instalación
- Configuramos ficheros “cassandra.yaml” y “cassandra-env.sh”, y nos aseguramos de darle valores distintos
  - MAX_HEAP, INITIAL_HEAP y JMX_PORT
  - cluster_name, sedes, listen_address, rpc_address
- Levantamos Cassandra desde la nueva dirección

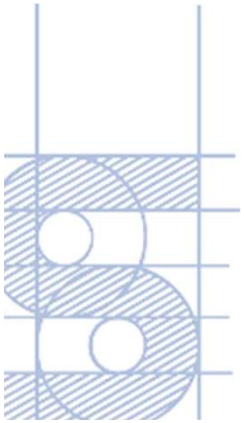

everis
an NTT DATA Company

¿Qué es Cassandra?

Data sharding

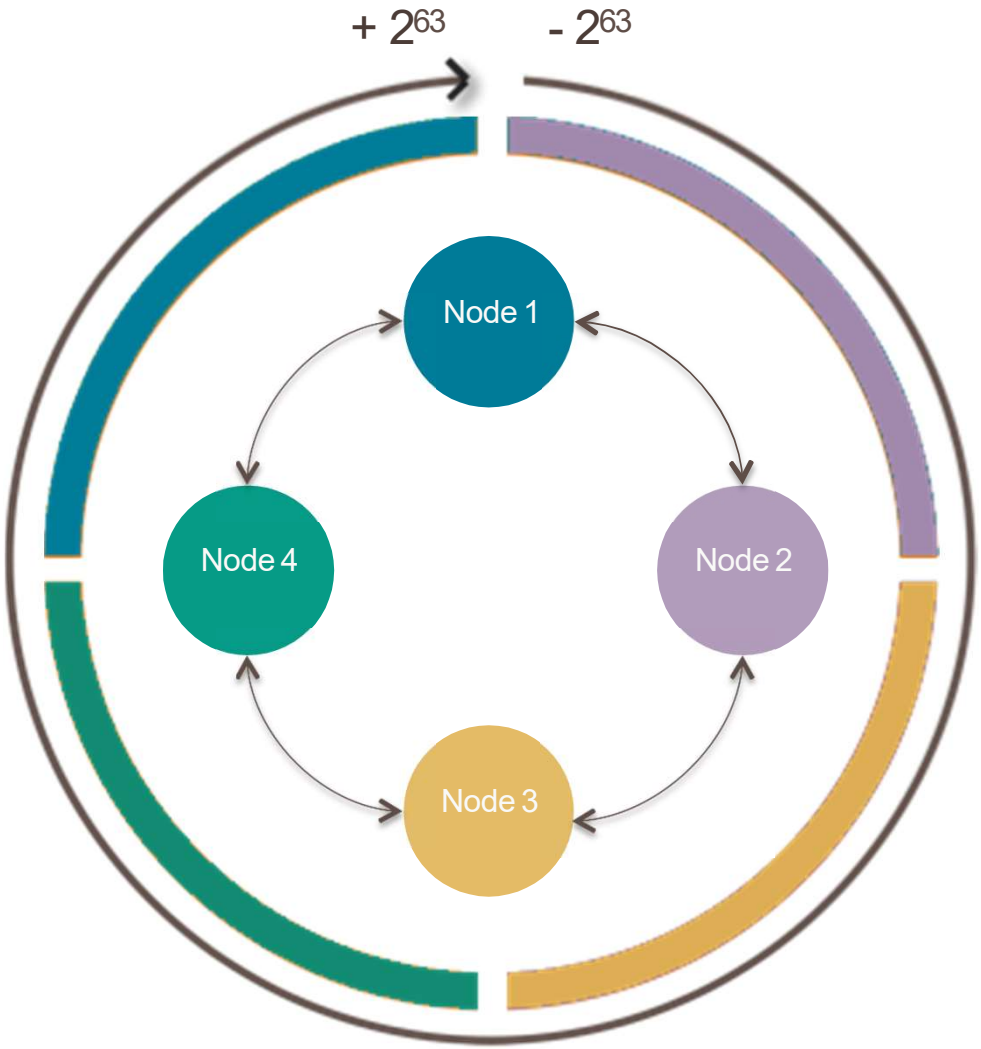

everis
an NTT DATA Company

¿Qué es Cassandra?

Data sharding

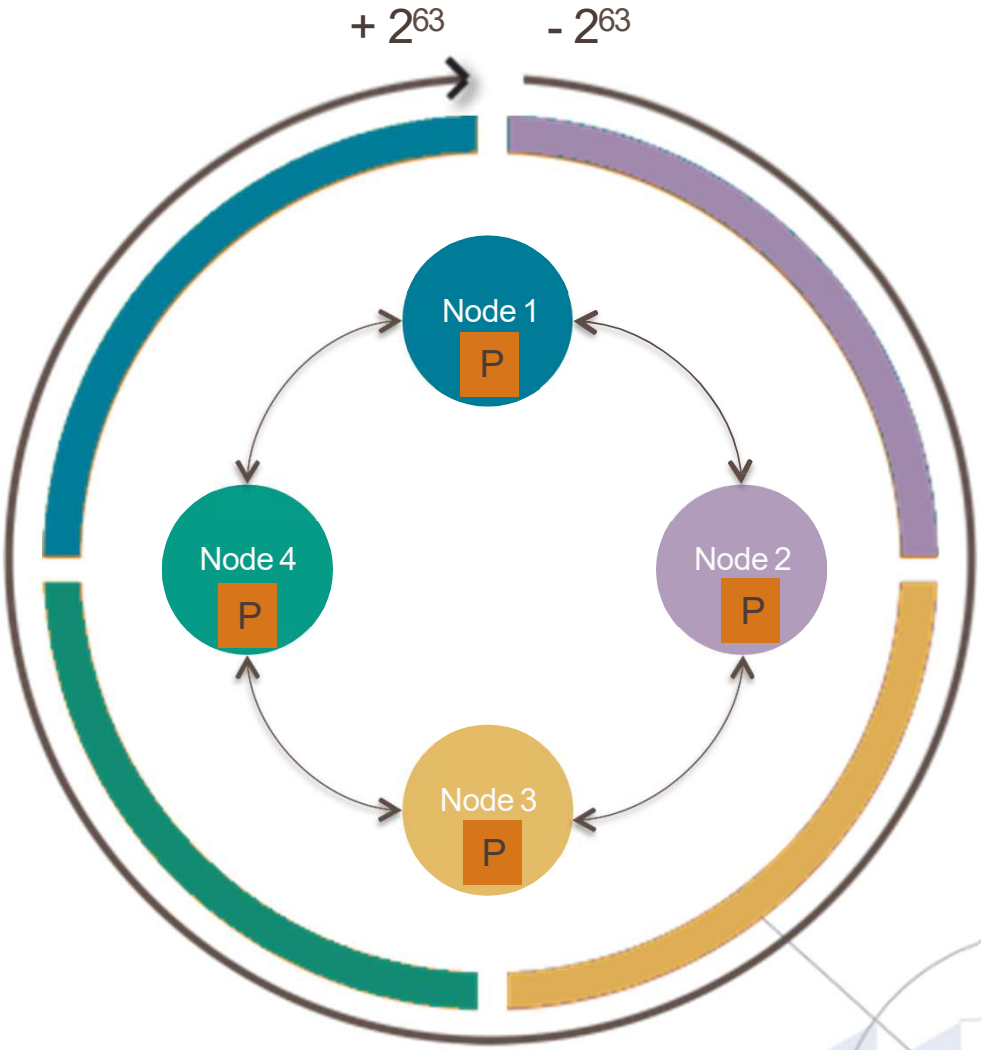

everis
an NTT DATA Company

¿Qué es Cassandra?

Data sharding

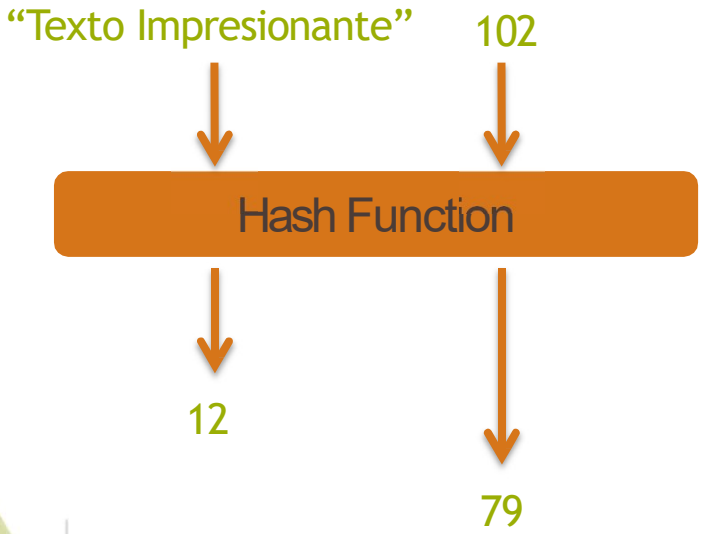

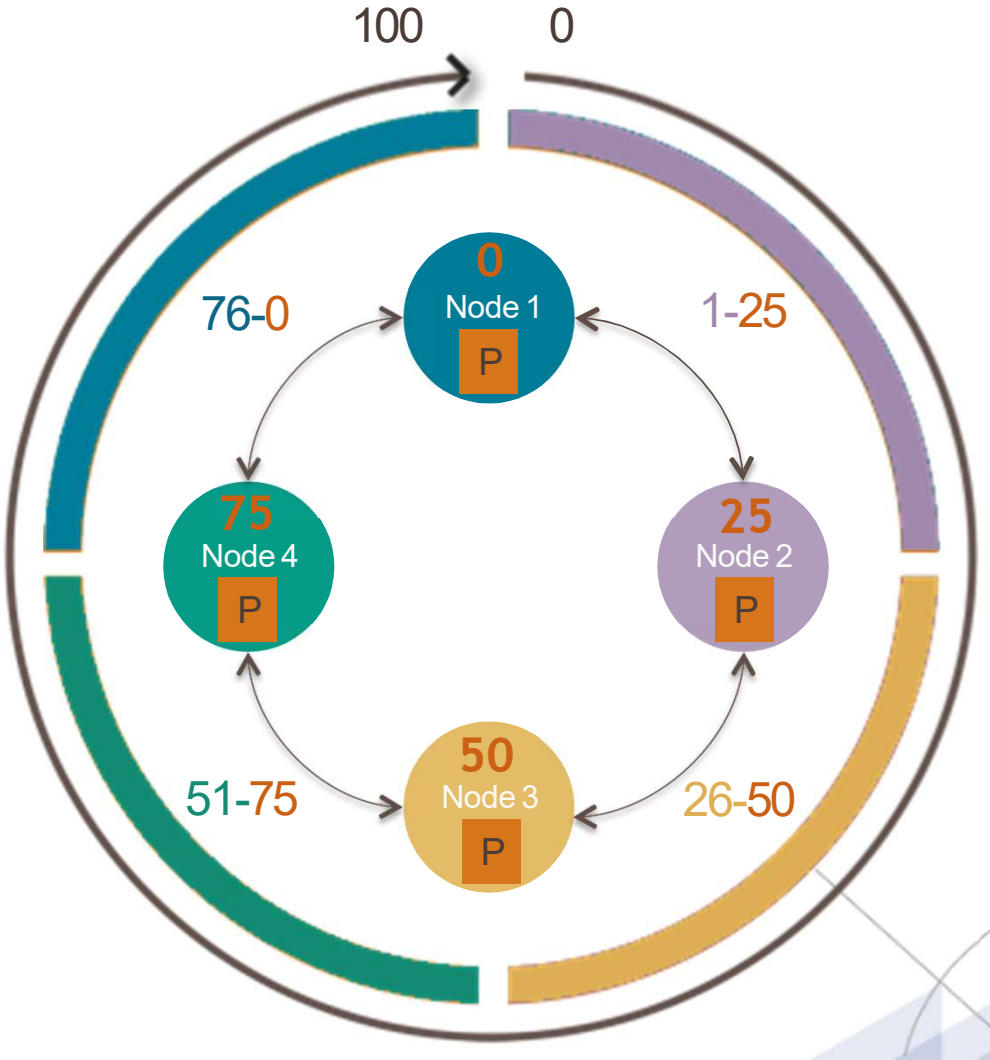

everis
an NTT DATA Company

¿Qué es Cassandra?

Data sharding

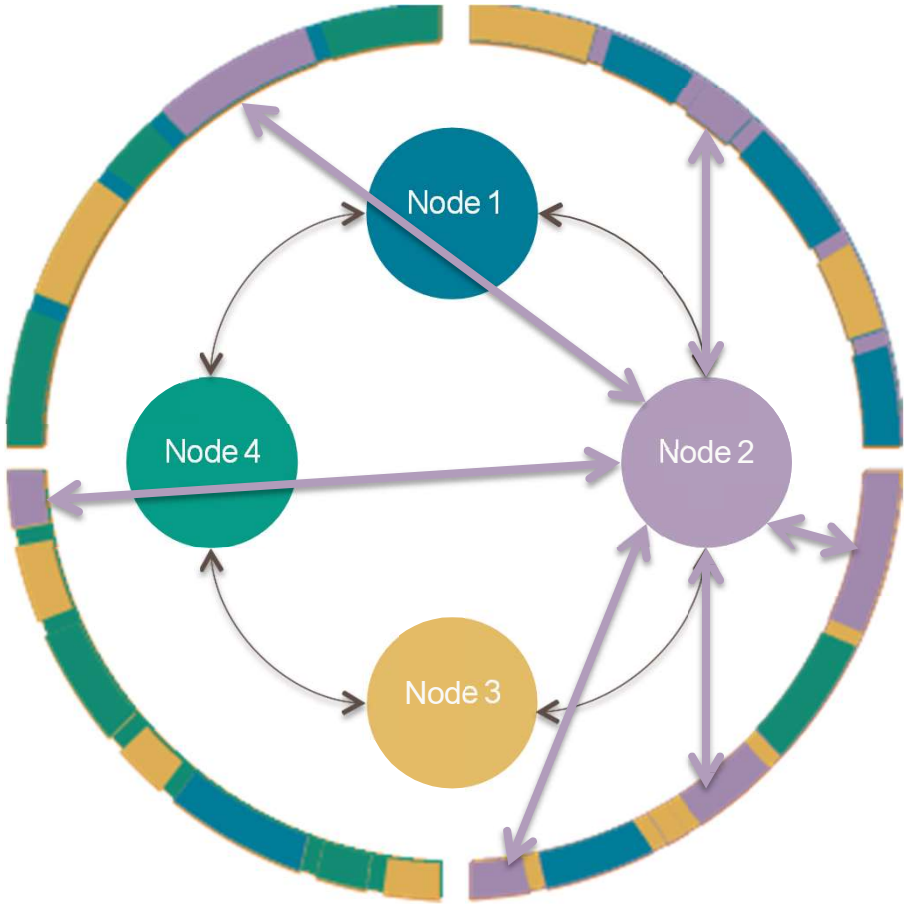

everis
an NTT DATA Company

A trabajar se ha dicho

Vamos a probar cómo funciona la distribución de datos

- Usa la herramienta “nodetool getendpoints” para saber dónde se ubican la casa Targaryen, Lannister, Greyjoy y Stark
- Para uno de los nodos con “nodetool stopdaemon -h ip -p puerto”, y confirma que las casas que allí se ubicaban ya no se pueden consultar vía cqlsh
- Arranca de nuevo el nodo y verifica que se pueden consultar

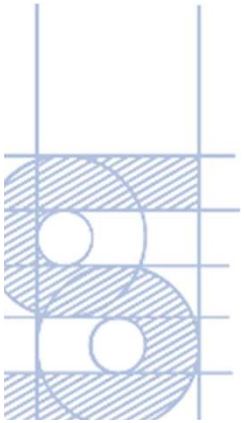

everis
an NTT DATA Company

¿Qué es Cassandra?

Coordination

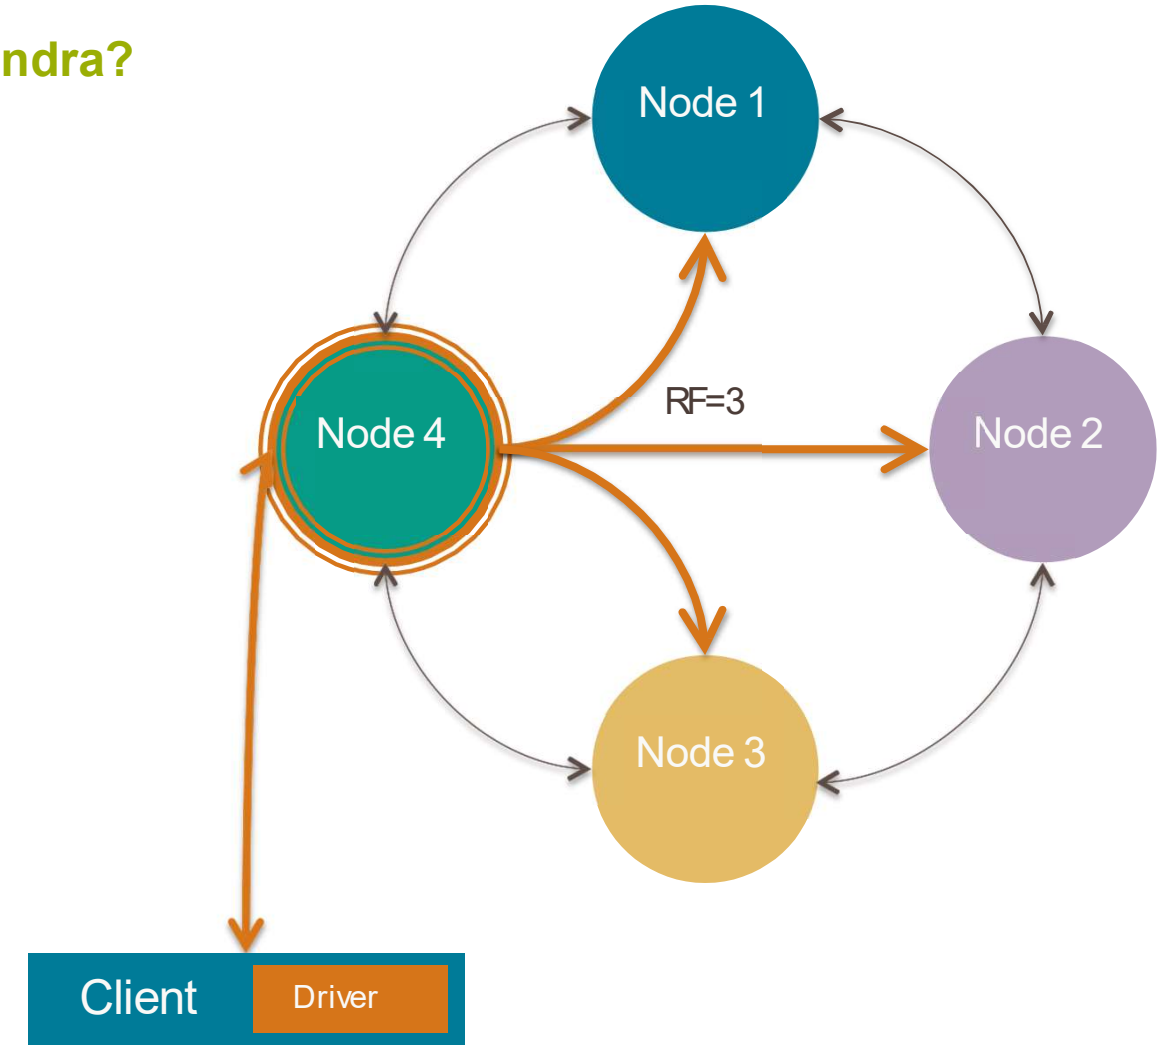

¿Qué es Cassandra?

Replication

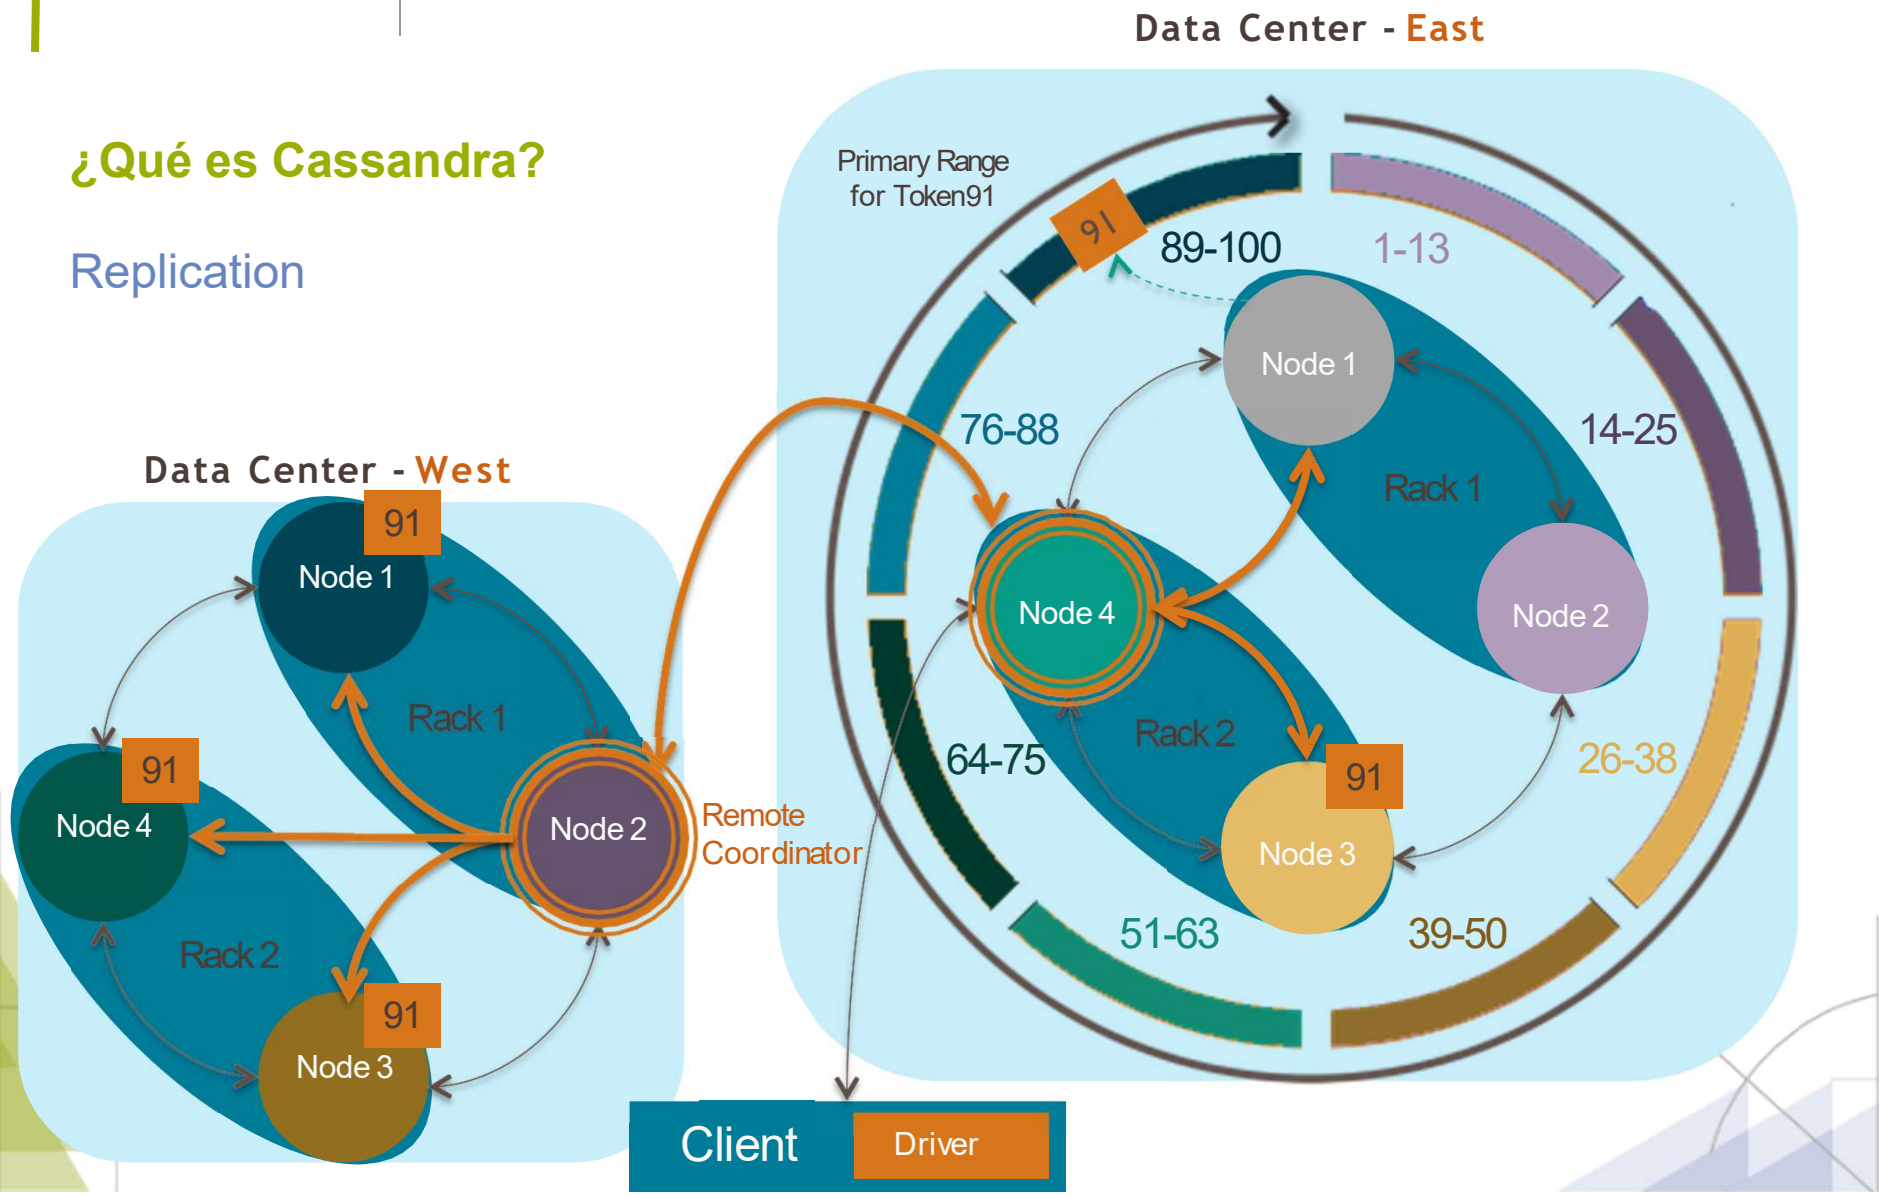

¿Qué es Cassandra?

Consistenca (configurable)

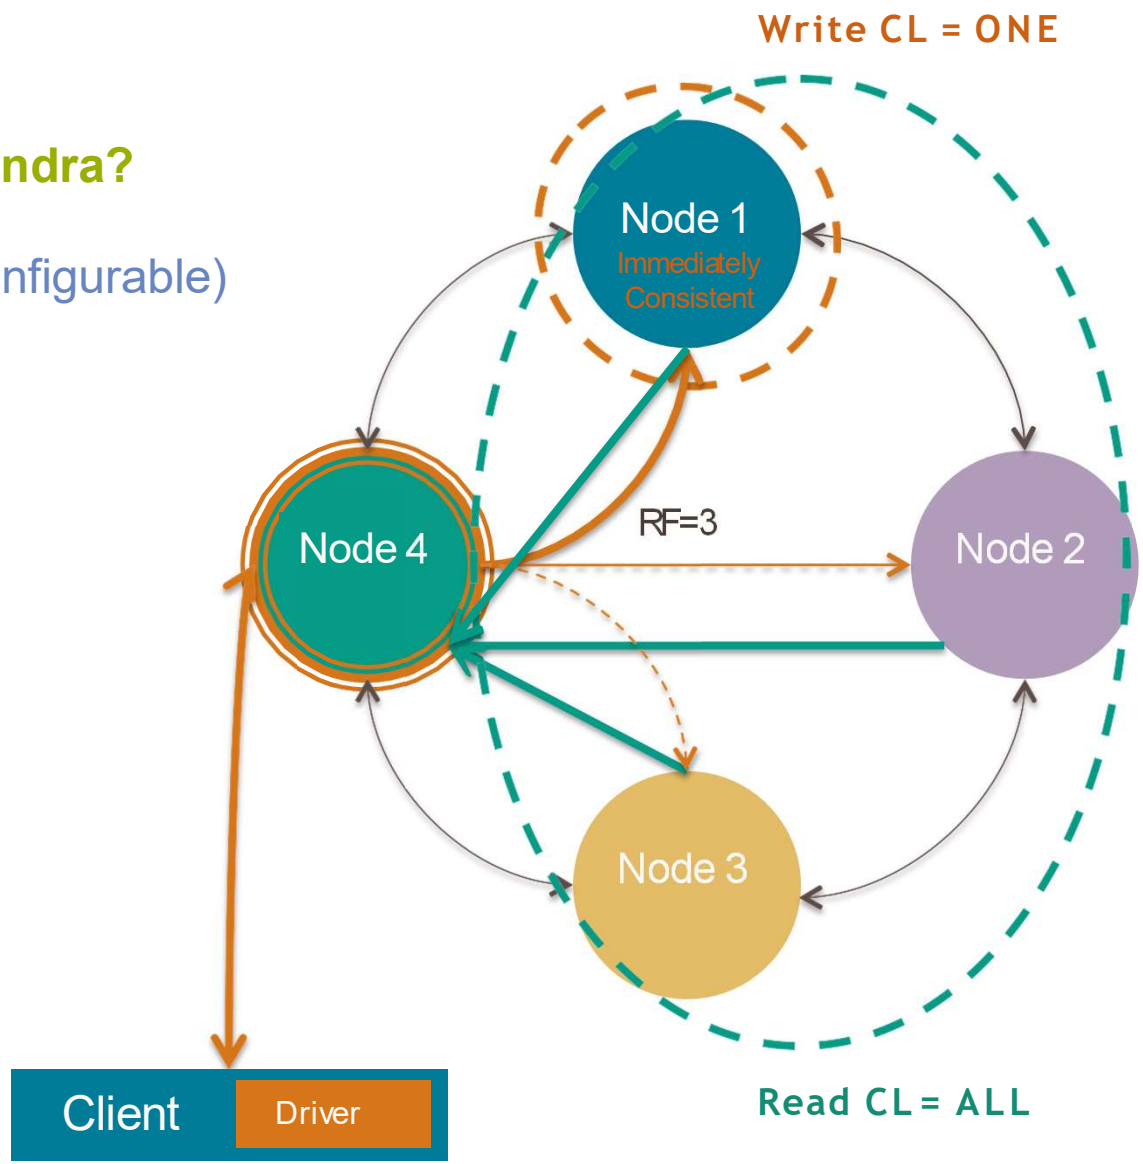

¿Qué es Cassandra?

Si tienes 2 relojes…

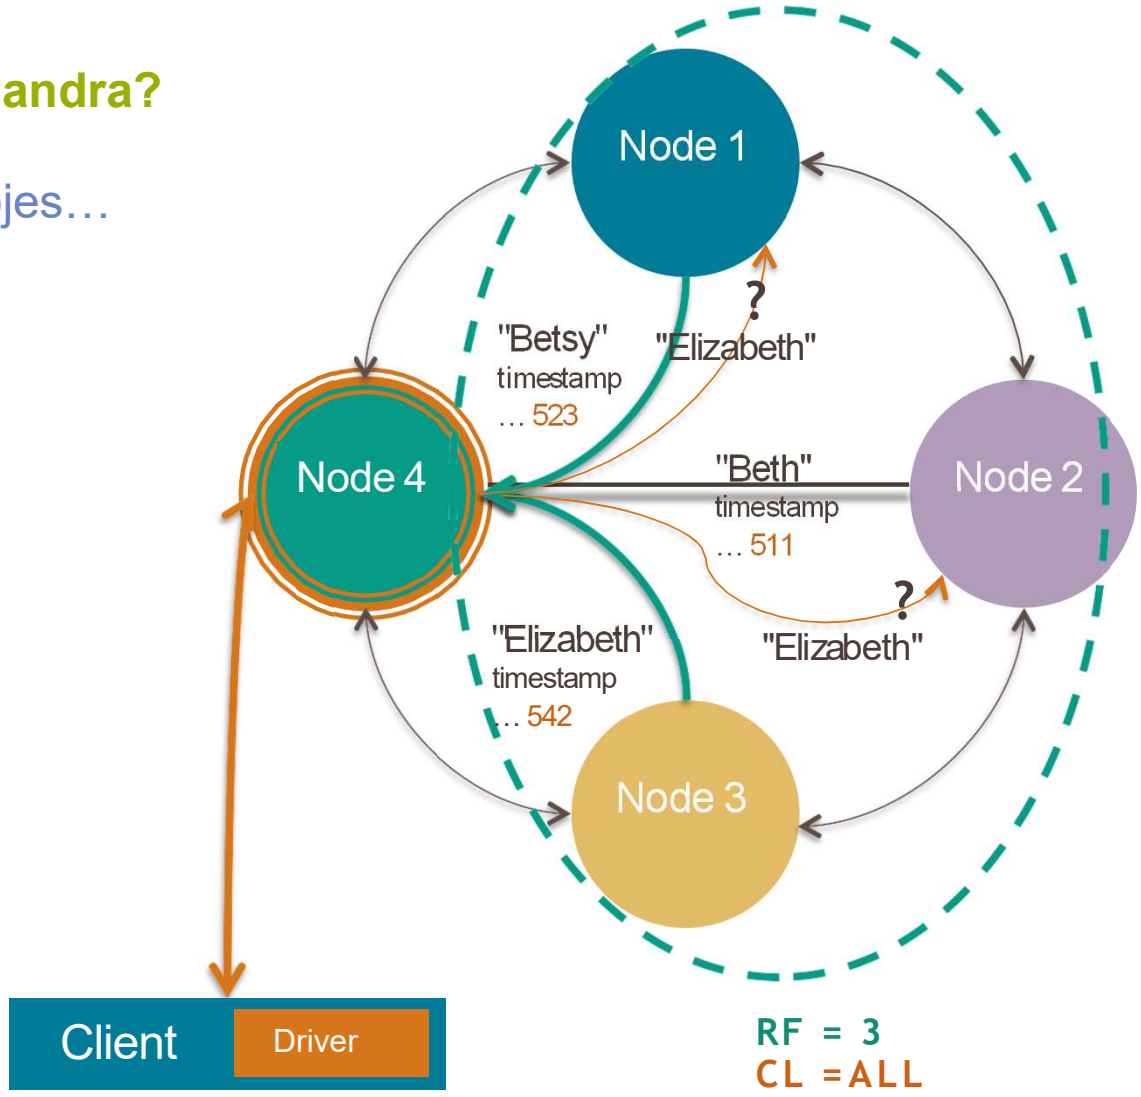

everis
an NTT DATA Company

A trabajar se ha dicho

Vamos a instalar un segundo nodo de Cassandra

- Borramos el keyspace westeros
- Volvemos a crearlo, pero esta vez con RF=2
- Cargamos todos los datos, como hicimos la primera vez
- Tiramos un nodo y verificamos que todo funciona igual
- Arrancamos nuevamente el nodo para dejarlo todo bien

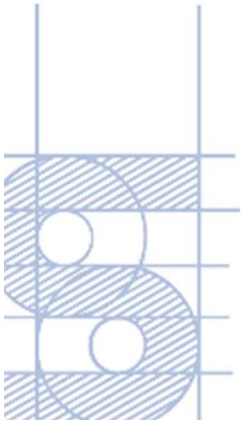

everis
an NTT DATA Company

Drivers Python

Mediante la herramienta pip de Python podemos instalar los drivers Cassandra

```
pip install cassandra-driver
```

Si la instalación falla, es necesario instalar cython (para los módulos en Python escritos en C y C++)

```
pip install cython
```

Si estamos ejecutando la VM, ya tenemos el driver instalado.

Si vamos a conectarnos desde otra máquina, desactivar antes el firewall.
Asegurarnos de que las IPs de los hosts son las públicas (si no, configurar forwarding)
Para que funcione, en cassandra.yaml, tenemos que configurar rpc_address y listen_address con la ip externa

En primer lugar, vamos a añadir los imports que vamos a usar

```
from cassandra.cluster import Cluster
from cassandra.policies import (TokenAwarePolicy,
DCAwareRoundRobinPolicy, RetryPolicy)
from cassandra.query import (PreparedStatement, BoundStatement)
```

Ahora tenemos que conectarnos al clúster (se dan una serie de nodos, el resto se obtiene por gossip).

```
cluster = Cluster(contact_points=['127.0.0.1'],
load_balancing_policy=
TokenAwarePolicy(DCAwareRoundRobinPolicy(local_dc='US-West')),
default_retry_policy = RetryPolicy() ,protocol_version=3 )
```

Como trabajamos en un clúster formado por varios nodos, vamos a especificar que las peticiones van a ir al nodo responsable de dicho token (primary range) con TokenAwarePolicy, y le indicamos cuál es el Data-Center que tiene que interpretar como local para realizar las querys
También especificamos la política de reintentos si la operación no ha finalizado

Una vez que estamos conectados al clúster, especificamos con qué keyspace vamos a trabajar

```
session = cluster.connect('keyspace1')
```

A partir de ahora, podemos lanzar querys sobre dicha sesión

```
# Insertar
prepared_stmt = session.prepare ( "INSERT INTO ejemplo_python
(col1,col2,col3) VALUES (?, ?, ?)")
bound_stmt = prepared_stmt.bind(['Jones','bob@example.com', 33])
stmt = session.execute(bound_stmt)

# select que devuelve nuestros datos
prepared_stmt = session.prepare ( "SELECT * FROM ejemplo_python
WHERE (col1 = ?)")
bound_stmt = prepared_stmt.bind(['Jones'])
stmt = session.execute(bound_stmt)
for x in stmt: print x.col2, x.col3
```

everis
an NTT DATA Company

A trabajar se ha dicho

Vamos a instalar un segundo nodo de Cassandra

- Hacer un programa que inserte datos en Cassandra en una nueva tabla y los muestre de alguna forma

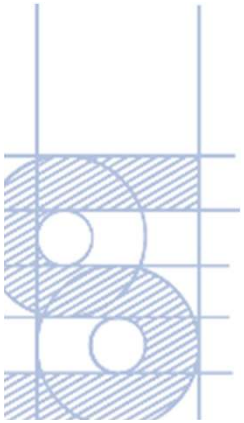

- Javier Gómez Santos

- javier.gomez.santos@ucm.es

- @Javi_Pronoide

- https://www.linkedin.com/in/javier-g%C3%B3mez-santos-7b182939/

- https://github.com/gatchan00

everis

an NTT DATA Company

Lo mejor está por llegar...

https://jobs.everis.com/es/ofertas/tu-oportunidad