## El Everest es pan comido: Escala fácilmente con Cassandra











Javier Gómez Santos

Data Alchemist



## Para hablar del evento

@everis

@Javi\_Pronoide

#Cassandra

#BigData





## Sobre mi

#### **Javier Gómez Santos**



#### Actualmente:

- Expert Big Data Architect @ Everis
- Profesor asociado @ UCM
- Presidente de la asociación Codernauts
- Colaborador @ Pronoide

#### En el pasado:

- Formador técnico @ Pronoide
- Investigador @ UCM
- · Backend developer @ Santander, CECA, Orange









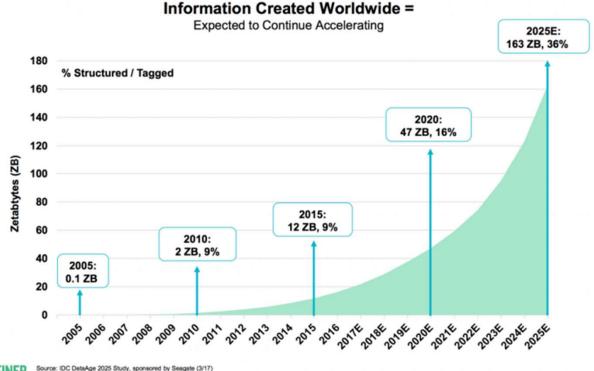


Motivaciones



#### Crecimiento de datos en los últimos años

# Data Volume Growth Continues @ Rapid Clip... % Structured / Tagged (~10%) Rising Fast...





Source: IDC DataAge 2025 Study, sponsored by Seagate (3/17) Note: 1 petabyte = 1MM gigabytes, 1 zeta byte = 1MM petabytes



## Imposible para gestionar por un sistema tradicional







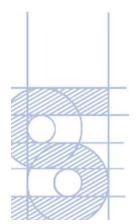






## ¿Qué enfoques aportan las BBDD NoSQL?

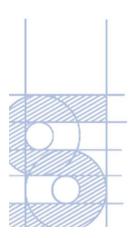
- Distribuye la información a través de múltiples nodos
- Es más laxo con la consistencia
- Es más laxo con los esquemas
- Busca optimizar la información para adaptarla a las necesidades actuales





## Hay 4 grandes enfoques a las bases de datos no-relacionales:

- Grafos
- Clave-Valor
- Documento
- Column Family



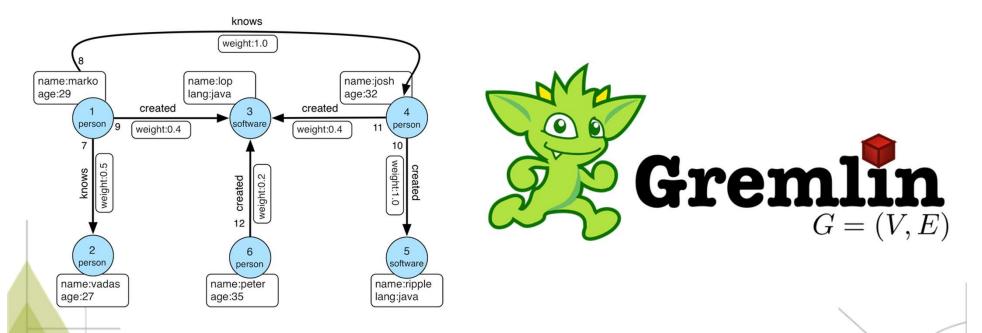


Motivaciones



#### **Grafos**

Los elementos están distribuidos como vértices de un grafo, siendo las uniones entre vértices las relaciones de ambos (con propiedades).

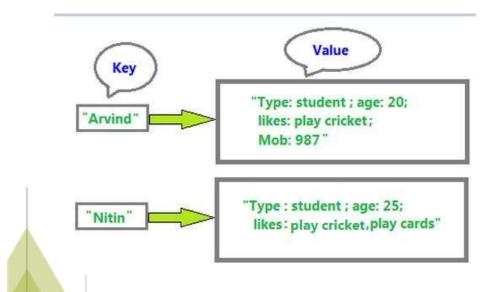


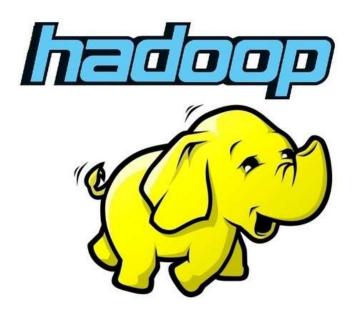
Motivaciones



#### **Clave-Valor**

Existen claves que enlazan a un conjunto de valores asociados a la misma de cualquier tipo





Big data

Motivaciones



#### **Documento**

Se almacenan conjuntos de documentos (JSON) que pueden ser consultados en su totalidad o en parte.

#### Students Document

```
{
    __id: "5373aadadcac133aad5b6660",
    name: "kaushal patel",
    email: "kp@example.com",
    courses: {
        course_name: "java",
        fees: "5000",
        duration: "3",
        professor: "g.r."
    }
}
```



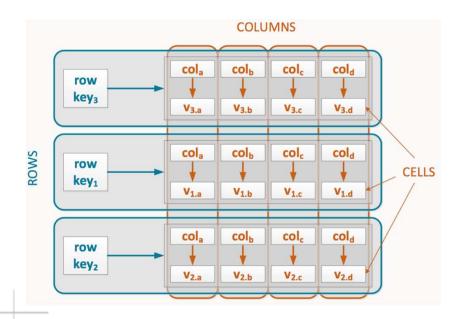
Powered By: pingax.com

Motivaciones



## **Column Family**

Las claves enlazan con un conjunto de columnas

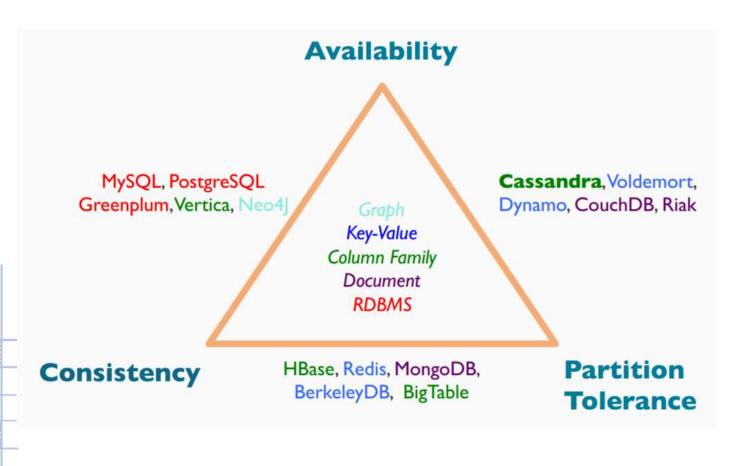




Motivaciones



#### El teorema CAP







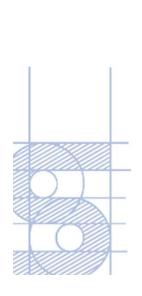




## **ADVERTENCIA:**

Esto es un taller práctico

Si en algún momento te quedaras atascado, ejecuta los scripts que hay en tu **home**, en la carpeta **SoyMuyVago** 











## ¿Qué es Cassandra?

#### Características

- Una base de datos NoSQL basada en Column Families.
- Posee un esquema definido, pero flexible, que permite su alteración.
- Usa un modelo totalmente distribuido, sin nodos maestros.





Ejercicio 1



## A trabajar se ha dicho

Vamos a instalar Cassandra y levantar el primer nodo

- Verificamos fichero /etc/hosts y nuestro hostname
- Verificamos JDK
- Descomprimimos Cassandra (y lo llevamos a \$home/cassandra\_1)
- Configuramos ficheros "cassandra.yaml" y "cassandra-env.sh"
  - MAX HEAP, INITIAL HEAP y JMX PORT
  - cluster\_name, seeds, listen\_address, rpc\_address
    - Listen address → nodos
    - Rpc\_address → clientes
    - Broadcast address → si los nodos se comunican con otra ip externa

Levantamos Cassandra





## ¿Qué es Cassandra?

Posee CQL, un lenguaje de consultas similar al SQL

```
-- Inserts or updates
INSERT INTO Standard1 (KEY, col0, col1)
VALUES (key, value0, value1)

vs.

-- Inserts or updates
UPDATE Standard1
SET col0=value0, col1=value1 WHERE KEY=key
```



## **Keyspace**

División lógica en la que vamos a trabajar

#### Crear un Keyspace:

CREATE KEYSPACE nombre\_keyspace WITH replication={'class':'SimpleStrategy', 'replication\_factor':3};

Asociar un Keyspace a la sesión actual de **cqlsh** USE nombre\_keyspace

Borrar un Keyspace y todos los datos que este posea DROP KEYSPACE nombre\_keyspace





#### **Table**

### Abstracción de una Column Family

```
CREATE TABLE performer (
name VARCHAR PRIMARY KEY,
type VARCHAR,
country VARCHAR,
style VARCHAR,
founded INT,
born INT,
died INT);
```



#### **CRUD**

## Acceso a los datos a través de la Partition Key

#### Insertar:

Insert into performer (name, type) values ('Paco', 'Cantautor');

#### Actualizar:

Update performer set type = 'Cantante' where name='Paco';

#### Borrar:

Delete performer where name='Paco';

#### Leer:

Select \* from perfomer where name='Paco':



Ejercicio 2



## A trabajar se ha dicho

Vamos a lanzar nuestras primeras querys

- Asegurémonos de que Cassandra está levantado (Si es necesario, usar "nodetool")
- Vamos a crear un keyspace
- Vamos a crear una tabla
- Insertaremos 1 dato
- Haremos un import de un CSV



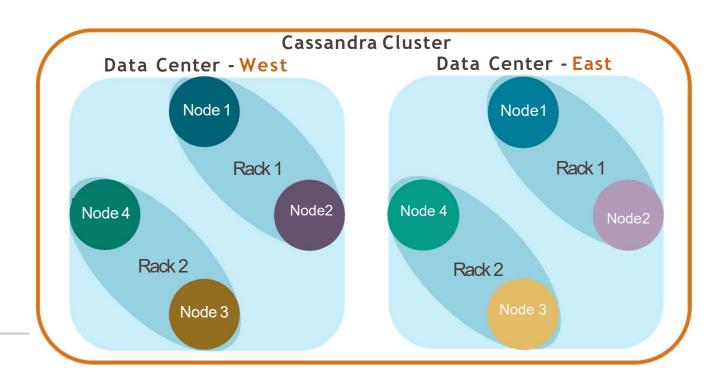






## ¿Qué es Cassandra?

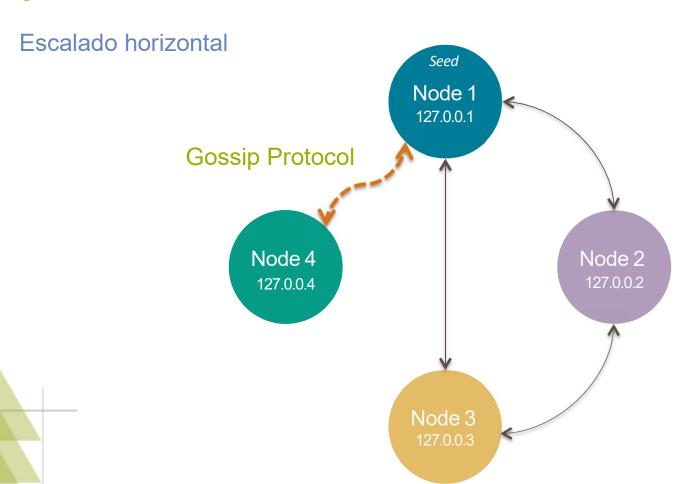
#### Clúster Cassandra







## ¿Qué es Cassandra?





Ejercicio 3



## A trabajar se ha dicho

Vamos a instalar un segundo nodo de Cassandra

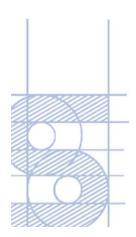
• Repetimos los pasos de la primera instalación

 Configuramos ficheros "cassandra.yaml" y "cassandra-env.sh", y nos aseguramos de darle valores distintos

• MAX HEAP, INITIAL HEAP y JMX PORT

• cluster\_name, sedes, listen\_address, rpc\_address

Levantamos Cassandra desde la nueva dirección





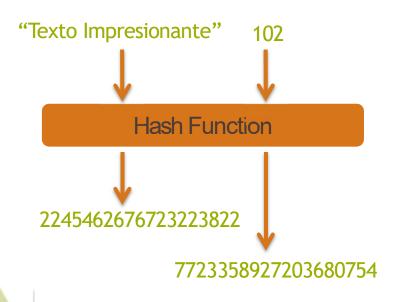


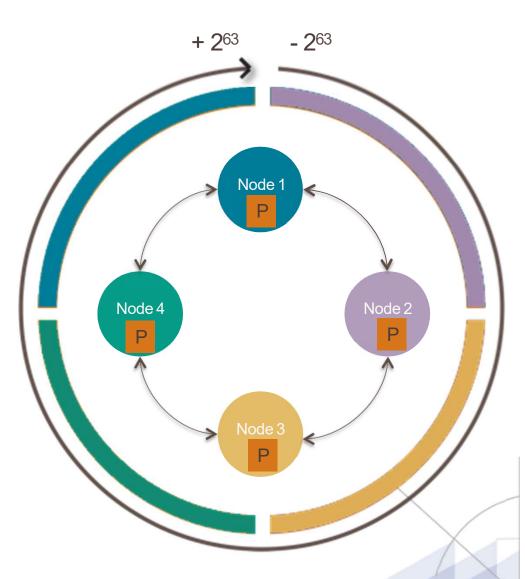
¿Qué es Cassandra?





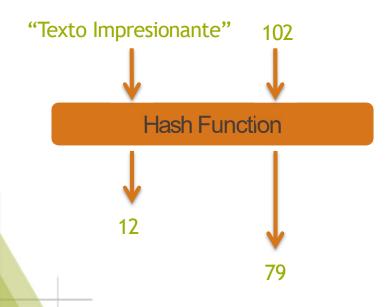
## ¿Qué es Cassandra?

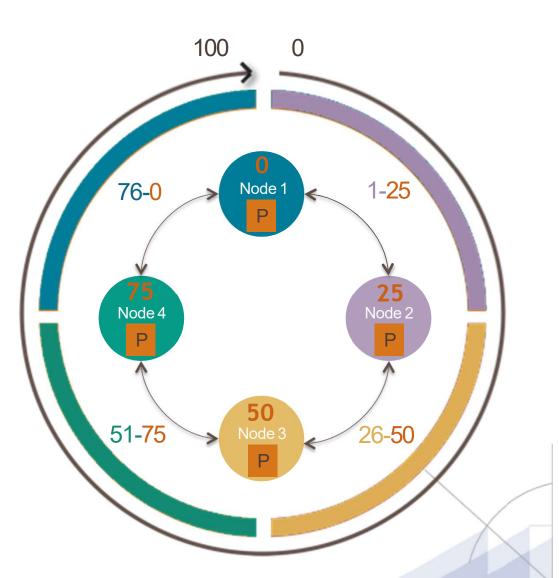






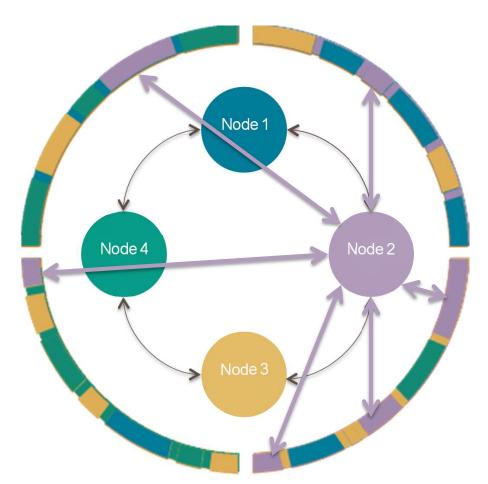
## ¿Qué es Cassandra?







## ¿Qué es Cassandra?





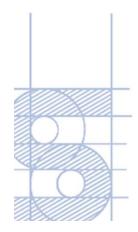
Ejercicio 4



## A trabajar se ha dicho

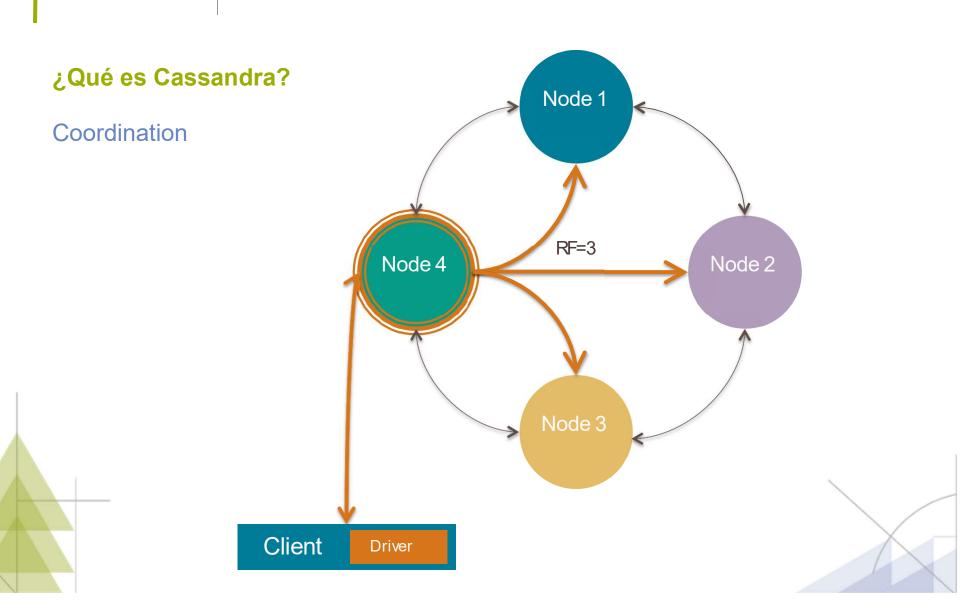
Vamos a probar cómo funciona la distribución de datos

- Usa la herramienta "nodetool getendpoints" para saber dónde se ubican la casa Targaryen, Lannister, Greyjoy y Stark
- Para uno de los nodos con "nodetool stopdaemon -h ip -p puerto", y confirma que las casas que allí se ubicaban ya no se pueden consultar vía cqlsh
- Arranca de nuevo el nodo y verifica que se pueden consultar



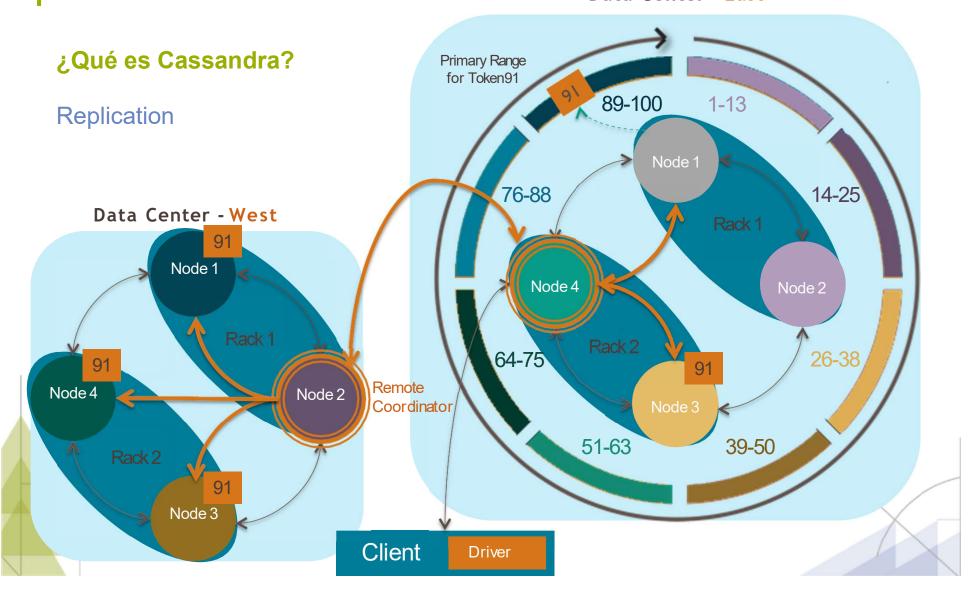






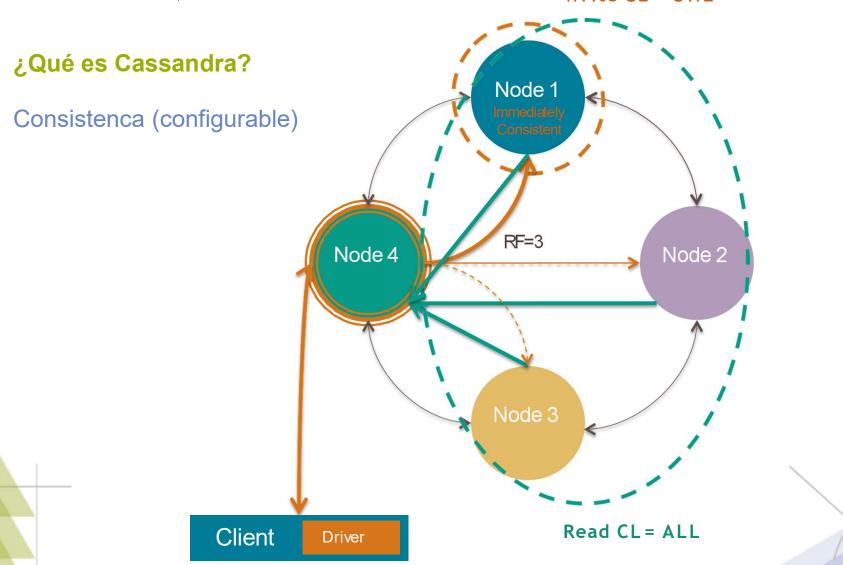


#### Data Center - East

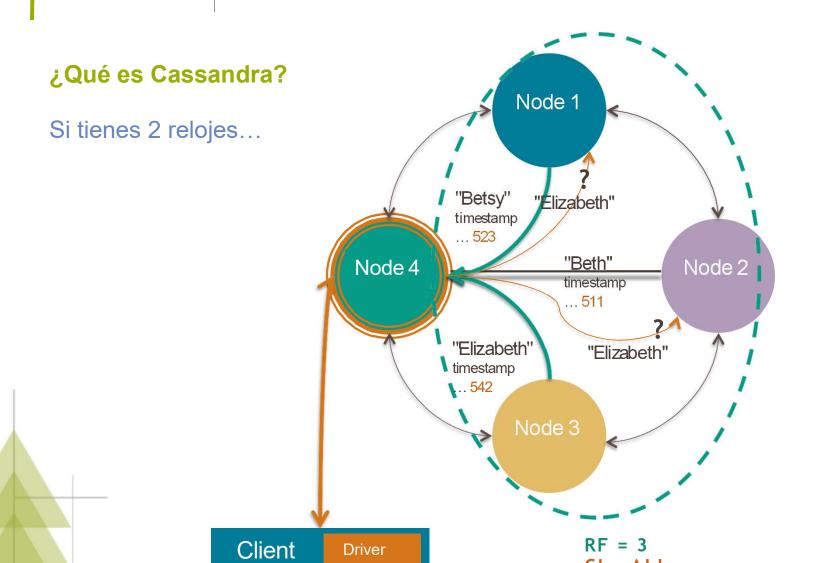




#### Write CL = ONE







CL = ALL



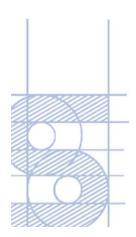
Ejercicio 5



## A trabajar se ha dicho

Vamos a instalar un segundo nodo de Cassandra

- Borramos el keyspace westeros
- Volvemos a crearlo, pero esta vez con RF=2
- Cargamos todos los datos, como hicimos la primera vez
- Tiramos un nodo y verificamos que todo funciona igual
- Arrancamos nuevamente el nodo para dejarlo todo bien









## **Drivers Python**

Mediante la herramienta pip de Python podemos instalar los drivers Cassandra

pip install cassandra-driver

Si la instalación falla, es necesario instalar cython (para los módulos en Python escritos en C y C++) pip install cython

Si estamos ejecutando la VM, ya tenemos el driver instalado.

Si vamos a conectarnos desde otra máquina, desactivar antes el firewall. Asegurarnos de que las IPs de los hosts son las públicas (si no, configurar forwarding)

Para que funcione, en cassandra.yaml, tenemos que configurar rpc\_address y listen\_address con la ip externa



#### En primer lugar, vamos a añadir los imports que vamos a usar

from cassandra.cluster import Cluster from cassandra.policies import (TokenAwarePolicy, DCAwareRoundRobinPolicy, RetryPolicy) from cassandra.query import (PreparedStatement, BoundStatement)

Ahora tenemos que conectarnos al clúster (se dan una serie de nodos, el resto se obtiene por gossip).

cluster = Cluster(contact\_points=['127.0.0.1'],
load\_balancing\_policy=
TokenAwarePolicy(DCAwareRoundRobinPolicy(local\_dc='US-West')),
default\_retry\_policy = RetryPolicy() ,protocol\_version=3 )

Como trabajamos en un clúster formado por varios nodos, vamos a especificar que las peticiones van a ir al nodo responsable de dicho token (primary range) con TokenAwarePolicy, y le indicamos cuál es el Data-Center que tiene que interpretar como local para realizar las querys También especificamos la política de reintentos si la operación no ha finalizado



Una vez que estamos conectados al clúster, especificamos con qué keyspace vamos a trabajar

```
session = cluster.connect('keyspace1')
```

```
A partir de ahora, podemos lanzar querys sobre dicha sesión
# Insertar
prepared_stmt = session.prepare ( "INSERT INTO ejemplo_python
(col1,col2,col3) VALUES (?, ?, ?)")
bound_stmt = prepared_stmt.bind(['Jones','bob@example.com', 33])
stmt = session.execute(bound_stmt)

# select que devuelve nuestros datos
prepared_stmt = session.prepare ( "SELECT * FROM ejemplo_python
WHERE (col1 = ?)")
bound_stmt = prepared_stmt.bind(['Jones'])
stmt = session.execute(bound_stmt)
for x in stmt: print x.col2, x.col3
```



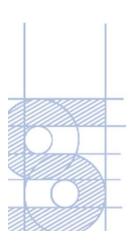
Ejercicio 5



## A trabajar se ha dicho

Vamos a instalar un segundo nodo de Cassandra

 Hacer un programa que inserte datos en Cassandra en una nueva tabla y los muestre de alguna forma









Javier Gómez Santos



• javier.gomez.santos@ucm.es



• @Javi\_Pronoide



• <a href="https://www.linkedin.com/in/javier-g%C3%B3mez-santos-7b182939/">https://www.linkedin.com/in/javier-g%C3%B3mez-santos-7b182939/</a>



• https://github.com/gatchan00







# Lo mejor está por llegar...

https://jobs.everis.com/es/ofertas/tu-oportunidad